Segmentación de inmuebles en arriendo con aprendizaje no supervisado: K-Means, PCA, SVD y clustering jerárquico

Ruby Dayana Cárdenas Gómez

Especialización en Inteligencia Artificial, Universidad de Cundinamarca

CADI Introducción a Machine Learning, período 2026-2

Ing. Wilson Rojas Reales, PhD(c)

25 de octubre de 2026

Repositorio del proyecto: https://github.com/RubyDayana/ml-no-supervisado-inmuebles

Resumen

Este informe aplica algoritmos de aprendizaje no supervisado a un portafolio de 1 000 inmuebles en arriendo para descubrir segmentos comerciales sin etiquetas previas. Se usó K-Means con tres tamaños de agrupamiento (k = 2, 3 y 4), se redujo la dimensionalidad con análisis de componentes principales (PCA), se demostró numéricamente que PCA equivale a la descomposición en valores singulares (SVD) de los datos centrados, y se contrastó el resultado con el clustering jerárquico de Ward. Antes de agrupar se auditó el archivo: se descartó una columna *Estrato* duplicada sin relación con ninguna otra variable y se detectó que la localidad y el tipo de inmueble contienen la misma información. Con las cuatro variables de tamaño y valor (área, habitaciones, estrato y precio) estandarizadas, K-Means con k = 3 identificó un segmento económico (41.9 %; 1.47 millones de pesos de arriendo promedio), uno intermedio (20.9 %; 3.13 millones) y uno premium (37.2 %; 6.35 millones, 65 % del recaudo). Las métricas internas favorecieron k = 2 (silueta 0.611), pero k = 3 fue el más útil comercialmente. PCA con las ocho columnas preprocesadas explicó 62.9 % de la varianza con dos componentes y mostró que usar todas las columnas, o solo dos componentes, produce segmentos engañosos que separan inmuebles equivalentes por número de baños. Ward con k = 3 coincidió con K-Means (índice de Rand ajustado = 0.975). Se recomienda agrupar con las variables informativas y usar PCA como herramienta de diagnóstico.

Palabras clave: aprendizaje no supervisado, K-Means, análisis de componentes principales, descomposición en valores singulares, clustering jerárquico, segmentación de inmuebles

Segmentación de inmuebles en arriendo con aprendizaje no supervisado: K-Means, PCA, SVD y clustering jerárquico

Una inmobiliaria que administra cientos de inmuebles en arriendo suele tomar decisiones de precio, publicidad y atención sin una clasificación formal de su portafolio. El aprendizaje no supervisado ofrece una alternativa: buscar grupos naturales en los datos sin que nadie haya definido de antemano a qué grupo pertenece cada inmueble (James et al., 2021). La actividad propuesta por el docente (Rojas Reales, 2026a) plantea ese escenario con un archivo de 1 000 inmuebles y pide aplicar K-Means, reducir la dimensionalidad con PCA y analizar los resultados con criterio comercial.

El objetivo general de este trabajo es segmentar el portafolio y recomendar qué enfoque conviene usar. Los objetivos específicos son: (a) auditar la calidad del conjunto de datos; (b) implementar K-Means con distintos valores de k y decidir cuál es el más útil; (c) aplicar PCA, interpretar sus componentes y medir la información que se pierde; (d) comprobar la relación entre PCA y la SVD y usar la SVD para comprimir una imagen, que es la aplicación clásica del tema en el curso (Rojas Reales, 2026c); y (e) contrastar K-Means con el clustering jerárquico.

El trabajo se desarrolló en tres notebooks de Google Colab con Python, scikit-learn (Pedregosa et al., 2011), pandas (McKinney, 2010) y Matplotlib (Hunter, 2007). Todo el código, con sus salidas, está en el repositorio https://github.com/RubyDayana/ml-no-supervisado-inmuebles, que se resume en la Tabla 1.

Tabla 1

Notebooks del repositorio

Notebook	Contenido
`01 KMeansSegmentacionInmuebles.ipynb`	Auditoría del dataset, script del docente, K-Means con k = 2, 3 y 4, perfil comercial y respuesta a las 11 preguntas.
`02 PCAyKMeansInmuebles.ipynb`	Preprocesamiento, PCA, varianza explicada, cargas, información perdida, K-Means sobre componentes y respuesta a las 7 preguntas.
`03 SVDyClusteringJerarquico.ipynb`	PCA como SVD, `TruncatedSVD`, aproximación de bajo rango, compresión de imágenes, enlaces y dendrograma.

Nota. Los tres notebooks se ejecutan en Google Colab; si el archivo de datos no está en la carpeta `datos/`, lo descargan del repositorio.

Marco conceptual

Aprendizaje no supervisado y clustering

En el aprendizaje supervisado los datos traen una respuesta conocida que el modelo aprende a predecir; en el no supervisado solo hay características y el objetivo es descubrir estructura en ellas (James et al., 2021). El *clustering* agrupa observaciones parecidas entre sí y

distintas de las de otros grupos. Como no existe una respuesta correcta con la cual comparar, la calidad de los grupos se juzga con métricas internas y con su utilidad para quien toma decisiones.

K-Means

K-Means reparte las observaciones en k grupos y representa cada grupo con su centroide, el promedio de sus miembros (MacQueen, 1967). El algoritmo alterna dos pasos, asignar cada punto al centroide más cercano y recalcular los centroides, hasta que las asignaciones dejan de cambiar (Lloyd, 1982), y minimiza la *inercia*, la suma de las distancias cuadradas de cada punto a su centroide. Como el resultado depende de los centroides iniciales, scikit-learn los elige con la estrategia k-means++ (Arthur y Vassilvitskii, 2007) y repite el ajuste varias veces (`n_init`). Al usar distancias, K-Means exige que las variables estén en escalas comparables.

Métricas de validación interna

Se usaron cuatro. La *inercia* sirve para el método del codo: siempre disminuye al aumentar k, y se busca el punto donde deja de caer de forma importante. El *coeficiente de silueta* compara, para cada punto, la distancia promedio a su propio grupo con la distancia al grupo vecino y varía entre −1 y 1 (Rousseeuw, 1987); Kaufman y Rousseeuw (1990) proponen interpretar 0.51–0.70 como estructura razonable y 0.26–0.50 como débil. El *índice de Davies-Bouldin* mide el solapamiento entre grupos y es mejor cuanto menor (Davies y Bouldin, 1979), y el *índice de Calinski-Harabasz* es el cociente entre la dispersión entre grupos y dentro de ellos, y es mejor cuanto mayor (Caliński y Harabasz, 1974). Para comparar dos agrupaciones se usó el *índice de Rand ajustado* (ARI), que vale 1 si son idénticas y cerca de 0 si coinciden solo por azar (Hubert y Arabie, 1985).

Análisis de componentes principales

PCA transforma las variables originales en componentes no correlacionados, ordenados por la varianza que capturan; el primero es la dirección de mayor variación y cada uno siguiente es perpendicular a los anteriores (Jolliffe y Cadima, 2016). Los pesos con que cada variable entra en un componente se llaman *cargas* y permiten interpretarlo. Quedarse con unos pocos componentes reduce la dimensionalidad a costa de perder la varianza de los descartados. Para decidir cuántos conservar se usan la gráfica de sedimentación, la varianza acumulada y el criterio de Kaiser (1960), que retiene los componentes con autovalor mayor que 1 cuando las variables están estandarizadas.

Descomposición en valores singulares

Toda matriz A de m × n se puede escribir como $A = U\Sigma V^{T}$, donde las columnas de U y V son direcciones ortonormales y Σ contiene los valores singulares, que miden la importancia

de cada dirección (Golub y Van Loan, 2013). Si se conservan solo los k mayores, se obtiene la mejor aproximación posible de rango k (Eckart y Young, 1936). PCA es la SVD de la matriz de datos centrada: las filas de V^T son los componentes y la varianza de cada uno es $\sigma^2/(n-1)$. De allí se deriva la aplicación clásica de compresión de imágenes: una matriz de $m \times n$ se aproxima guardando $k\cdot(m+n+1)$ números en lugar de $m\cdot n$.

Clustering jerárquico

El clustering aglomerativo parte de cada observación como su propio grupo y une en cada paso los dos más cercanos, de modo que construye todos los agrupamientos posibles y el número de grupos se decide después, cortando el árbol o *dendrograma* (James et al., 2021). La distancia entre grupos depende del criterio de enlace: *single*, *complete*, *average* o *Ward*, que une los grupos cuya fusión aumenta menos la varianza interna (Ward, 1963). La *correlación cofenética* mide qué tan fielmente el árbol conserva las distancias originales (Sokal y Rohlf, 1962).

Método

Datos

El docente entregó el archivo `DATASET_Inmuebles.xlsx` (Rojas Reales, 2026b) con 1 000 inmuebles y diez columnas: identificador, área, habitaciones, estrato, precio de arriendo, baños, antigüedad, localidad, tipo de inmueble y una segunda columna *Estrato*. No hay valores nulos ni filas duplicadas y los identificadores son únicos. El identificador se conservó para reconocer los registros, pero no se usó como característica, como pide el enunciado.

Auditoría del dataset

Se encontraron cuatro hallazgos que condicionan el análisis (ver Tabla 2). El más importante es el de la columna *Estrato* duplicada, que se resolvió con la evidencia de los datos y se deja señalado para confirmación del docente.

Tabla 2

Hallazgos de la auditoría del dataset

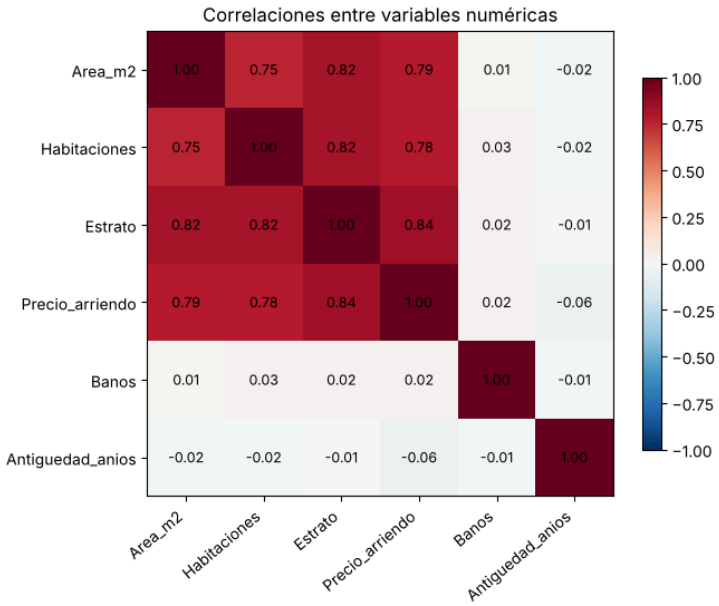
Hallazgo	Evidencia	Decisión
Encabezado `Antig[uedad`	Error de digitación (corchete en lugar de ü).	Se renombran las columnas.
Estrato aparece dos veces (columnas D y J)	La columna D (valores 2–6) tiene correlación de 0.838 con el precio; la J (valores 1–4) de 0.025. Coinciden en 16.7 % de las filas, frente a 15.3 % esperado por azar.	La segunda se trata como columna espuria y se descarta. Se usa la D.
Localidad y tipo de inmueble son la misma información	Todo Chapinero es casa, todo Suba es apartamento y todo Usaquén es apartaestudio.	Se usa solo `Localidad`, como el script del docente.
Baños y antigüedad no se relacionan con nada	Correlaciones entre −0.06 y 0.03 con las demás variables; precio promedio de 3.60 y 3.67 millones con uno y dos baños.	Se tienen en cuenta al interpretar PCA y los agrupamientos.

Nota. Fuente: cálculos propios, notebook 01. Los valores de correlación son de Pearson.

Además, área, habitaciones, estrato y precio están muy correlacionados entre sí (0.75 a 0.84), de modo que describen esencialmente una sola dimensión: qué tan grande y valioso es el inmueble (Figura 1). Esta redundancia explica varios de los resultados que siguen.

Figura 1

Correlaciones entre las variables numéricas del dataset



Nota. Las cuatro variables de tamaño y valor forman un bloque correlacionado; baños y antigüedad no se correlacionan con ninguna variable.

Preprocesamiento y herramientas

Las variables numéricas se estandarizaron con `StandardScaler` (media 0, desviación 1). En los experimentos de PCA, la localidad se codificó con `OneHotEncoder` en tres columnas,

de modo que la matriz preprocesada tiene 8 columnas: las 5 numéricas y las 3 de localidad. K-Means se ajustó siempre con `random_state=42` y `n_init=10`. Como K-Means numera los grupos de forma arbitraria, los grupos se renumeraron de menor a mayor precio promedio, de modo que el grupo 0 siempre es el más económico. El código se ejecutó en Python 3 con scikit-learn, pandas, NumPy, SciPy y Matplotlib.

Resultados

Parte 1. K-Means

Script del docente y modificación para leer el Excel

Primero se ejecutó el script `KMeansSegInmuebles.py` con sus 12 inmuebles de ejemplo, que separa tres segmentos: 6 económicos, 3 intermedios y 3 premium. Luego se modificó para leer las 1 000 filas del Excel, conservar el identificador sin usarlo, escalar las cuatro variables y renumerar los grupos por precio (Anexo A). Con los datos completos reaparecen los mismos tres segmentos (Tabla 3 y Figura 2).

Tabla 3

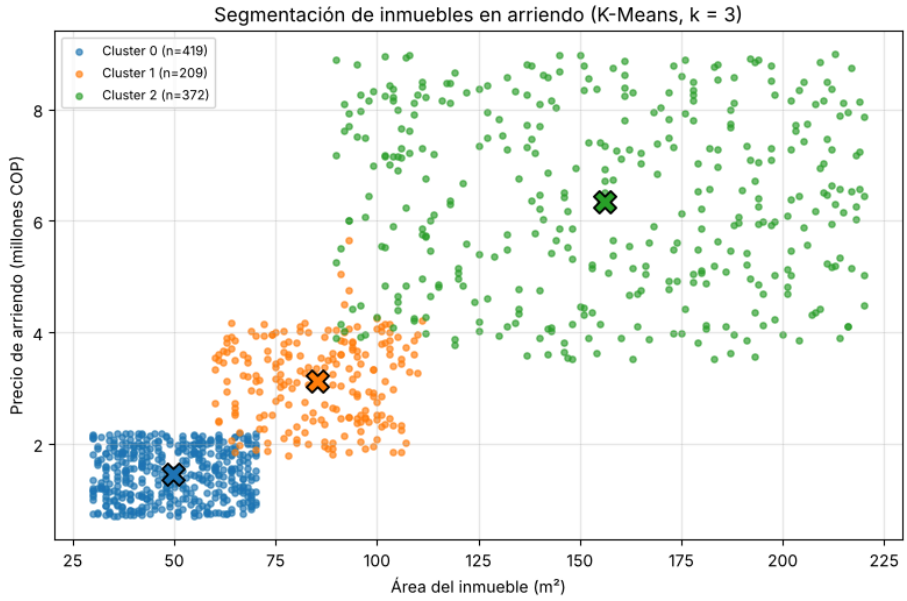
Perfil de los tres segmentos de K-Means (k = 3)

Segmento	Inmuebles	%	Área (m²)	Hab.	Estrato	Arriendo (COP)	COP/m²
0 — Económico	419	41.9	49.7	1.5	2.5	1 469 202	31 406
1 — Intermedio	209	20.9	85.4	2.5	4.1	3 130 625	37 695
2 — Premium	372	37.2	156.1	4.0	5.5	6 353 200	43 608

Nota. Valores promedio por segmento en la escala original. Fuente: notebook 01.

Figura 2

Segmentación de los 1 000 inmuebles con K-Means (k = 3)



Nota. Las X marcan los centroides. Los datos forman una escalera continua, sin vacíos claros entre segmentos, salvo entre los inmuebles pequeños y los grandes.

Efecto de no escalar

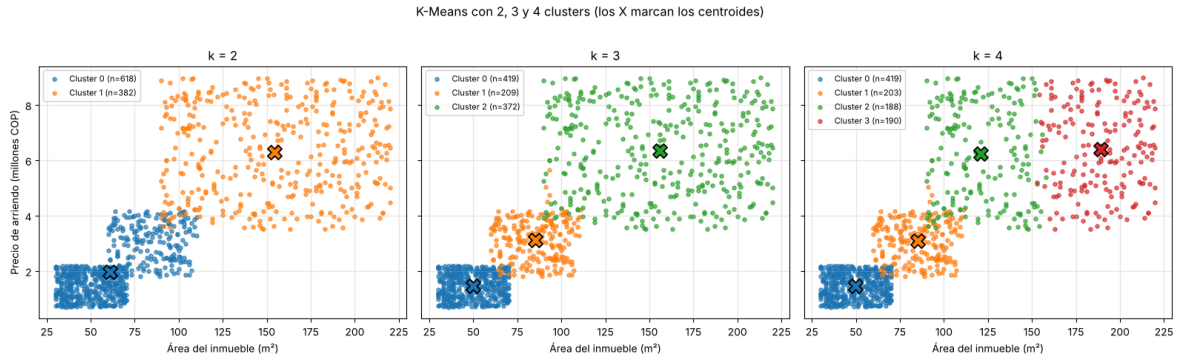
Sin escalar, el precio aporta el 100 % de la varianza total (su desviación estándar es de 2.4 millones, frente a 54.1 del área y alrededor de 1.3 de habitaciones y estrato), y los grupos son idénticos a los obtenidos agrupando solo por precio (ARI = 1.000). Al escalar, 228 de los 1 000 inmuebles (22.8 %) cambian de grupo y cada variable aporta el 25 %. Aun escalado, el precio sigue pesando más de lo que parece, porque área, habitaciones y estrato le repiten la misma información (correlaciones de 0.78 a 0.84): escalar iguala las escalas, pero no elimina la redundancia.

¿Cuántos clusters? k = 2, 3 y 4

La actividad pide repetir el modelo con `n_clusters` igual a 2 y 4 (Figura 3) y decidir cuál es más útil. Las métricas internas (Tabla 4) favorecen k = 2 y empeoran al subir k. El método del codo muestra que la inercia cae 72.1 % al pasar de 1 a 2 grupos, 31.2 % de 2 a 3 y 19.2 % de 3 a 4, y desde allí cerca de 12 % por paso (Figura 4). La silueta de k = 2 (0.611) indica estructura razonable según Kaufman y Rousseeuw (1990); la de k = 3 (0.482) y k = 4 (0.427), estructura débil. La razón es que los datos no forman islas separadas sino una escalera continua, y la única brecha clara es la que separa los inmuebles pequeños de los grandes.

Figura 3

K-Means con 2, 3 y 4 grupos



Nota. Los centroides se marcan con X. Con k = 4 el segmento premium se divide en dos por tamaño.

Tabla 4

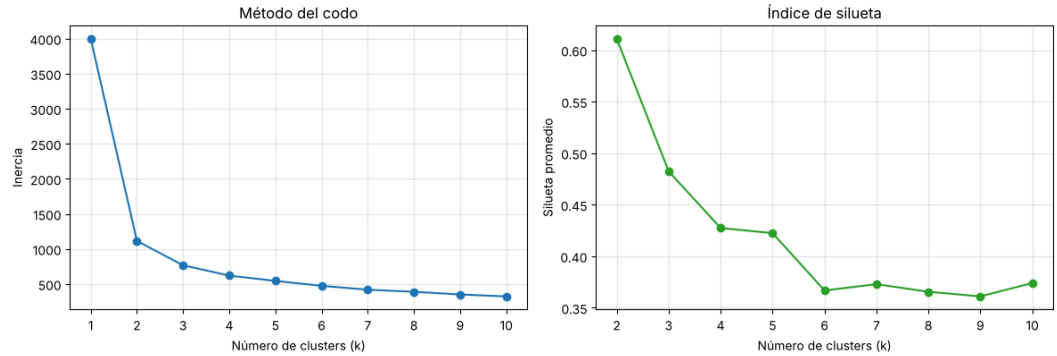
Métricas internas según el número de grupos

k	Inercia	Silueta	Davies-Bouldin	Calinski-Harabasz	Grupo más pequeño (%)
2	1 115.2	0.611	0.592	2 581.6	38.2
3	767.2	0.482	0.716	2 100.5	20.9
4	620.2	0.427	1.155	1 809.2	18.8

Nota. Mejor es mayor para silueta y Calinski-Harabasz, y menor para inercia y Davies-Bouldin. Fuente: notebook 01.

Figura 4

Método del codo e índice de silueta para k entre 1 y 10



Nota. La inercia cae con fuerza hasta k = 2 y con suavidad desde k = 3; la silueta es máxima en k = 2.

Se concluye que **k = 3 es el más útil para la operación comercial**, con k = 4 como refinamiento opcional. Con k = 2 (618 y 382 inmuebles) se separan inmuebles pequeños y baratos (61 m², 1.98 millones) de grandes y caros (154.6 m², 6.30 millones), pero el primer grupo mezcla económicos de 1.47 millones con intermedios de 3.13 millones, y no permite estrategias distintas. Con k = 3 se recuperan los tres niveles del enunciado, con un segmento menor de 20.9 % del portafolio. Con k = 4 el económico (419) y el intermedio (203) casi no cambian y el premium se parte en uno compacto (188 inmuebles, 121.1 m², 53 124 COP/m²) y

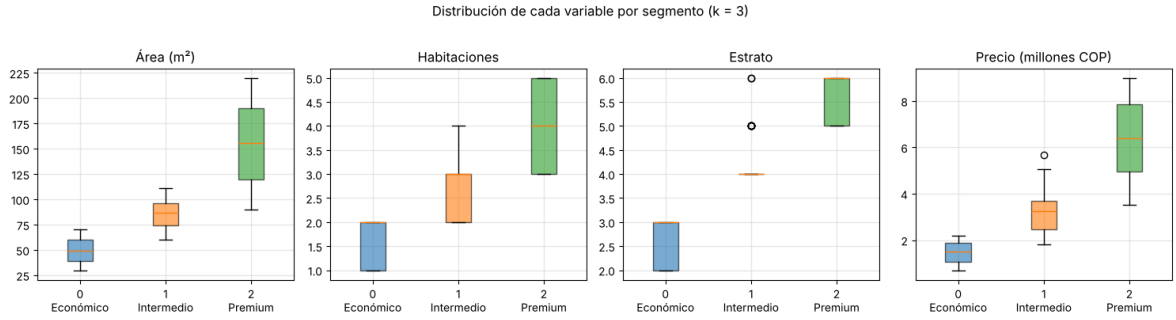
uno amplio (190 inmuebles, 188.9 m², 34 190 COP/m²) con arriendos casi iguales (6.24 y 6.39 millones): es una distinción comercialmente interesante, pero el corte cae dentro de una nube continua, y la silueta baja a 0.427.

Perfil comercial y concentración del recaudo

Las distribuciones por segmento se ven en la Figura 5. El segmento premium es 37.2 % de los inmuebles pero genera cerca del 65 % del arriendo mensual (2 363 de 3 633 millones), mientras que el económico, con 41.9 % de los inmuebles, aporta 16.9 %. La localidad no distingue los segmentos: la prueba chi-cuadrado no encuentra dependencia significativa (χ^2 = 7.67, gl = 4, p = 0.105; V de Cramér = 0.062). Lo que separa los segmentos es el tamaño y el valor del inmueble, no su ubicación.

Figura 5

Distribución de cada variable por segmento (k = 3)



Nota. Diagramas de caja de área, habitaciones, estrato y precio en cada segmento.

Respuestas a las preguntas del enunciado (K-Means)

1. ¿Por qué este ejercicio corresponde a aprendizaje no supervisado?

Porque los datos no traen una etiqueta que el algoritmo deba predecir: nadie indicó a qué segmento pertenece cada inmueble. K-Means recibe solo las características y descubre los grupos a partir de la similitud entre registros (James et al., 2021).

2. ¿Cuál es la diferencia entre clasificación y clustering?

La clasificación es supervisada: aprende de ejemplos con etiqueta conocida para predecir la etiqueta de ejemplos nuevos y se evalúa contra la etiqueta real. El clustering es no supervisado: crea los grupos a partir de los datos, no hay respuesta correcta con la cual compararlos, y el analista los interpreta, los nombra y los valida con métricas internas y con su utilidad.

3. ¿Qué representa un cluster en este caso?

Un segmento comercial: inmuebles parecidos entre sí en tamaño, habitaciones, estrato y precio. Su centroide es el inmueble típico del grupo (por ejemplo, el del segmento premium: 156 m², 4 habitaciones, estrato 5.5 y 6.35 millones).

4. ¿Por qué el precio de arriendo puede influir mucho en el resultado?

Por la escala y por la redundancia. K-Means usa distancias y el precio se mide en millones, de modo que sin escalar aporta el 100 % de la varianza y los grupos coinciden con los de agrupar solo por precio (ARI = 1.000). Y área, habitaciones y estrato están correlacionados con él (0.78 a 0.84), por lo que, incluso escalados, le repiten la misma información.

5. ¿Cuántos clusters se definieron?

Tres en el modelo principal (`n_clusters=3`, el valor del script). Se evaluaron además dos y cuatro y se concluyó que k = 3 es el más útil.

6. ¿Qué características tiene cada cluster?

Las de la Tabla 3: el económico (419 inmuebles) mide 49.7 m², tiene 1.5 habitaciones y estrato 2.5, con arriendo de 1.47 millones; el intermedio (209) mide 85.4 m², 2.5 habitaciones y estrato 4.1, con 3.13 millones; el premium (372) mide 156.1 m², 4.0 habitaciones y estrato 5.5, con 6.35 millones, y aporta 65 % del recaudo.

7. ¿Qué estrategia comercial se podría aplicar para cada grupo?

Se resumen en la Tabla 5.

Tabla 5

Estrategia comercial propuesta por segmento

Segmento	Cliente probable	Estrategia
Económico	Estudiantes, parejas jóvenes, primer arriendo	Volumen y rotación: portales masivos, trámites ágiles, precios competitivos, incentivos por pago puntual y servicios complementarios como el seguro de arriendo.
Intermedio	Familias pequeñas, profesionales	Resaltar la relación entre precio y valor, ofrecer flexibilidad (mascotas, plazos) y fidelizar para que al crecer la familia pasen al segmento siguiente sin salir de la inmobiliaria.
Premium	Familias grandes, ejecutivos	Atención personalizada con asesor dedicado, fotografía profesional, publicación selectiva y contratos largos con administración incluida. Como aporta cerca del 65 % del recaudo, merece las acciones de retención más cuidadosas.

Nota. Los perfiles de cliente son hipótesis comerciales derivadas de las características de cada segmento, no resultados del modelo.

8. ¿Cómo podría usar esta segmentación una inmobiliaria?

Para fijar y revisar precios (comparar un inmueble con el precio por metro cuadrado típico de su segmento), asignar asesores y presupuesto de marketing según el aporte de cada segmento, planear el portafolio (depender de un solo segmento para el 65 % del recaudo es un riesgo de concentración), dirigir campañas a cada perfil de cliente y medir resultados por segmento.

9. ¿Qué pasaría si se utilizara `n_clusters=2`?

Se obtienen un grupo de 618 inmuebles (61 m², 1.8 habitaciones, estrato 3.0, 1.98 millones) y otro de 382 (154.6 m², 4.0 habitaciones, estrato 5.5, 6.30 millones). Tiene las mejores métricas

(silueta 0.611) porque separa la única brecha clara, pero es demasiado grueso: junta económicos e intermedios con precios que difieren casi al doble.

10. ¿Qué pasaría si se utilizara `n_clusters=4`?

El económico (419) y el intermedio (203) casi no cambian y el premium se divide en compacto (188 inmuebles, 53 124 COP/m²) y amplio (190 inmuebles, 34 190 COP/m²), con arriendos casi iguales. La silueta baja a 0.427 y Davies-Bouldin sube a 1.155. Es útil solo si se quiere diferenciar el premium por precio por metro cuadrado.

11. ¿Cómo puede K-Means ayudar a mejorar las recomendaciones a los clientes?

Permite pasar de buscar entre mil inmuebles a buscar dentro del segmento correcto. La necesidad del cliente se convierte en un punto, el modelo lo asigna a un segmento con `predict` y se recomiendan los inmuebles de ese segmento más cercanos a su perfil. Para un cliente que busca 80 m², 3 habitaciones, estrato 4 y 3 millones, el modelo lo ubica en el segmento intermedio y propone cinco inmuebles muy próximos a lo pedido (distancias de 0.02 a 0.11 desviaciones estándar). Los centroides de los segmentos vecinos permiten mostrar qué obtendría el cliente pagando un poco más o menos.

Parte 2. PCA

Dimensiones y varianza explicada

El script del docente usa seis características (precio, área, habitaciones, baños, antigüedad y localidad). Al codificar la localidad en tres columnas, la matriz preprocesada tiene 8 dimensiones (1 000 × 8). La localidad no se estandariza, por lo que la varianza total no es 8 sino 5 + 3 × 0.222 ≈ 5.67. La Tabla 6 y la Figura 6 muestran cómo se reparte.

Tabla 6

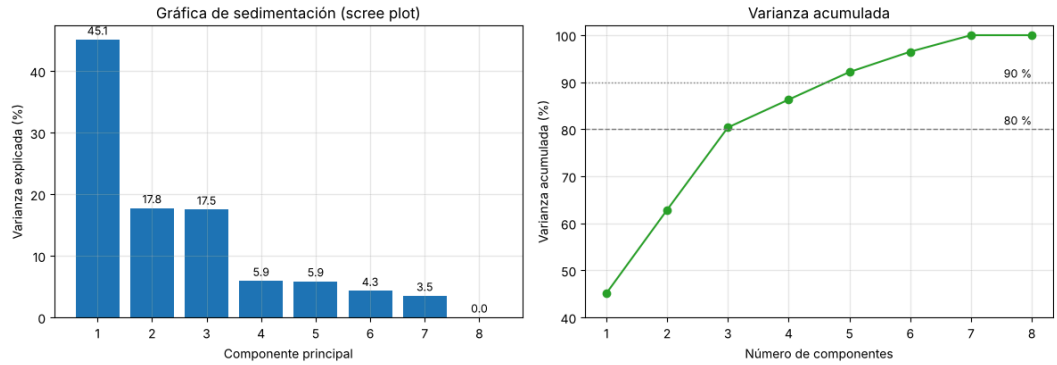
Varianza explicada por componente principal

Componente	Autovalor	Varianza explicada (%)	Acumulada (%)
PC1	2.559	45.106	45.106
PC2	1.007	17.756	62.862
PC3	0.994	17.522	80.384
PC4	0.336	5.925	86.309
PC5	0.333	5.864	92.173
PC6	0.245	4.316	96.489
PC7	0.199	3.511	100.000
PC8	0.000	0.000	100.000

Nota. Sobre las 8 columnas preprocesadas. Fuente: notebook 02.

Figura 6

Gráfica de sedimentación y varianza acumulada



Nota. Se necesitan 3 componentes para conservar al menos 80 % de la varianza y 5 para el 90 %.

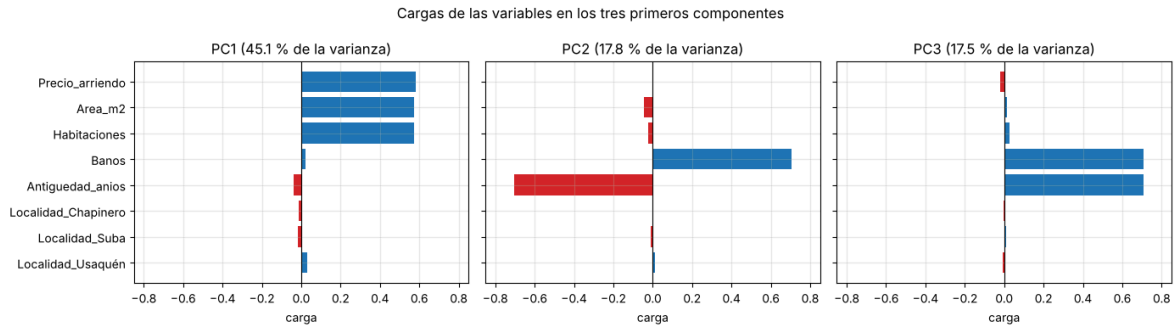
El PC1 concentra el 45.1 % de la varianza. PC2 y PC3 son casi idénticos (autovalores de 1.007 y 0.994), por lo que el criterio de Kaiser (1960) no es concluyente: indica 2 componentes, pero PC3 queda a una milésima del umbral. El octavo componente tiene varianza cero porque las tres columnas de localidad suman siempre 1 (colinealidad exacta), de modo que el espacio de datos tiene en realidad 7 dimensiones. Con dos componentes se conserva el 62.9 % de la varianza y se pierde el 37.1 %.

Interpretación de los componentes

Las cargas (Figura 7) muestran que PC1 es un índice de tamaño y valor (precio 0.582, área 0.574 y habitaciones 0.573); PC2 contrasta baños (+0.707) con antigüedad (−0.705) y PC3 los suma (0.707 y 0.706); la localidad no carga en ninguno (el plano resultante se ve en la Figura 8 y el biplot en la Figura 9). Como los autovalores de PC2 y PC3 son casi iguales, sus ejes no están definidos de forma única: cualquier rotación del par explica lo mismo.

Figura 7

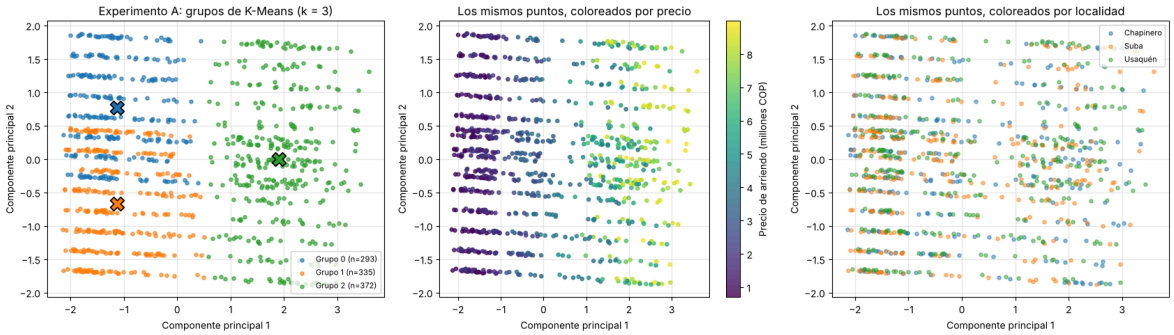
Cargas de las variables en los tres primeros componentes



Nota. Azul, carga positiva; rojo, negativa.

Figura 8

Plano PC1–PC2 con los grupos de K-Means, el precio y la localidad



Nota. Izquierda, grupos del experimento A (K-Means sobre las 8 columnas); centro, color según precio; derecha, color según localidad.

Experimento A: K-Means sobre las 8 columnas preprocesadas

Al aplicar K-Means con k = 3 a todas las columnas preprocesadas aparece un resultado inesperado (Tabla 7): los grupos 0 y 1 tienen el mismo precio (diferencia de 4.5 %), el mismo área y las mismas habitaciones, y solo se distinguen por el número de baños (2 frente a 1). Es decir, el algoritmo no encontró económico, intermedio y premium, sino pequeño con dos baños, pequeño con un baño y grande. La silueta en las 8 dimensiones es 0.278.

Tabla 7

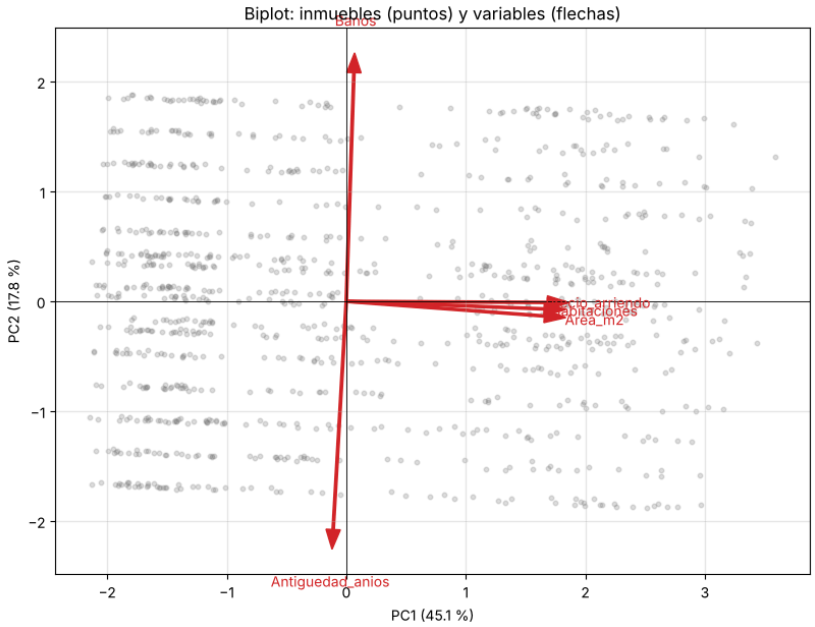
Perfil de los grupos del experimento A (K-Means sobre 8 columnas)

Grupo	Inmuebles	Arriendo (COP)	Área (m²)	Habitaciones	Baños	Antigüedad
0	293	1 974 711	60.9	1.84	2.0	8.5
1	335	2 063 615	62.2	1.87	1.0	8.6
2	372	6 353 186	156.1	4.03	1.5	8.3

Nota. Fuente: notebook 02.

Figura 9

Biplot de inmuebles y variables en el plano PC1–PC2



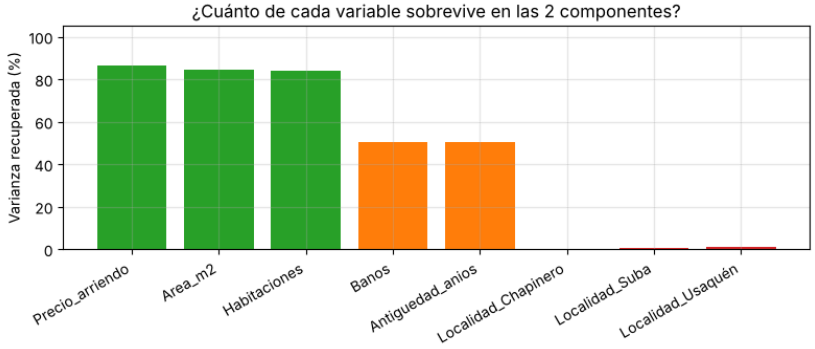
Nota. Precio, área y habitaciones apuntan en la misma dirección (están correlacionadas); baños y antigüedad son perpendiculares a ellas.

Información que se pierde con dos componentes

Al reconstruir las 8 columnas con `inverse_transform` a partir de dos componentes, la información se pierde de forma desigual (Figura 10): se recupera 86.6 % de la varianza del precio, 84.4 % de la del área y 84.0 % de la de habitaciones; solo 50.4 % de la de baños y de la de antigüedad; y entre 0.1 % y 1.0 % de la de la localidad. Si la ubicación fuera importante para el negocio, la representación en dos componentes la ocultaría. Además, las distancias en el plano no son exactamente las distancias reales y PCA solo captura relaciones lineales.

Figura 10

Varianza de cada variable que se recupera con dos componentes



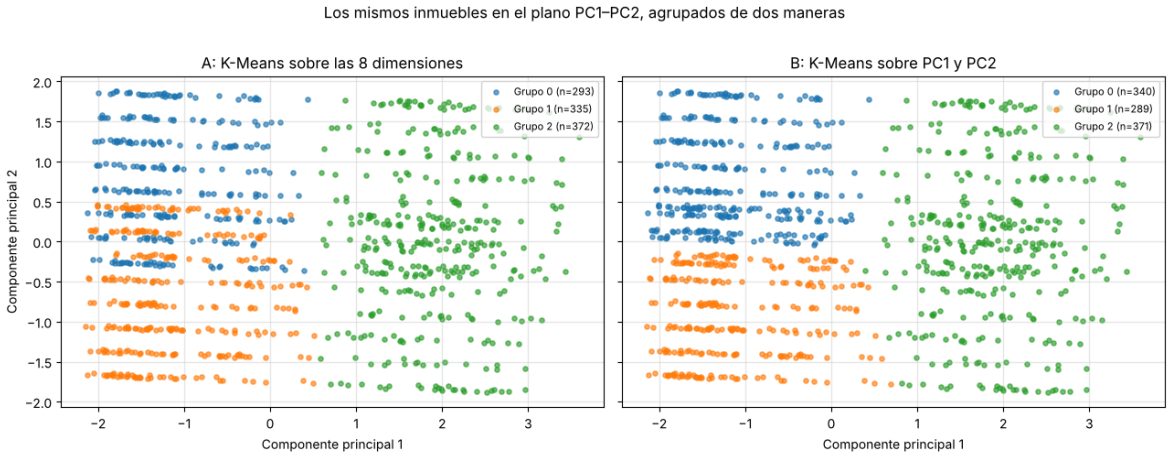
Nota. Verde: 84–87 %; naranja: 50 %; localidad: prácticamente nada.

Experimento B: K-Means sobre los componentes principales

Con dos componentes, los grupos cambian respecto al experimento A (Figura 11; ARI = 0.711; 127 inmuebles, 12.7 %, cambian de grupo, casi todos del bloque pequeño; 370 de 372 premium coinciden). Con tres componentes (80.4 % de la varianza) o más, los grupos son idénticos (ARI = 1.000). El experimento B tampoco encuentra económico, intermedio y premium: parte el bloque pequeño por PC2, que mezcla baños y antigüedad. La silueta de B en su propio espacio (0.440) no es comparable con la de A (0.278) porque los espacios tienen distinta dimensión; medidas en las 8 dimensiones, B es peor (0.227).

Figura 11

Mismos inmuebles agrupados de dos maneras en el plano PC1–PC2



Nota. A, K-Means sobre las 8 dimensiones; B, K-Means sobre PC1 y PC2.

Tabla 8

Qué variables definen cada agrupación (η²)

Variable	A: 8 dimensiones	B: 2 componentes
Precio de arriendo	0.738	0.736
Área	0.714	0.715
Habitaciones	0.678	0.677
Baños	0.627	0.239
Antigüedad	0.003	0.203

Nota. η² es la proporción de la varianza de cada variable explicada por la pertenencia al grupo. Fuente: notebook 02.

Baños y antigüedad no tienen relación con el valor del inmueble y aun así K-Means las usa para separar grupos, porque estandarizadas pesan lo mismo que el precio (Tabla 8).

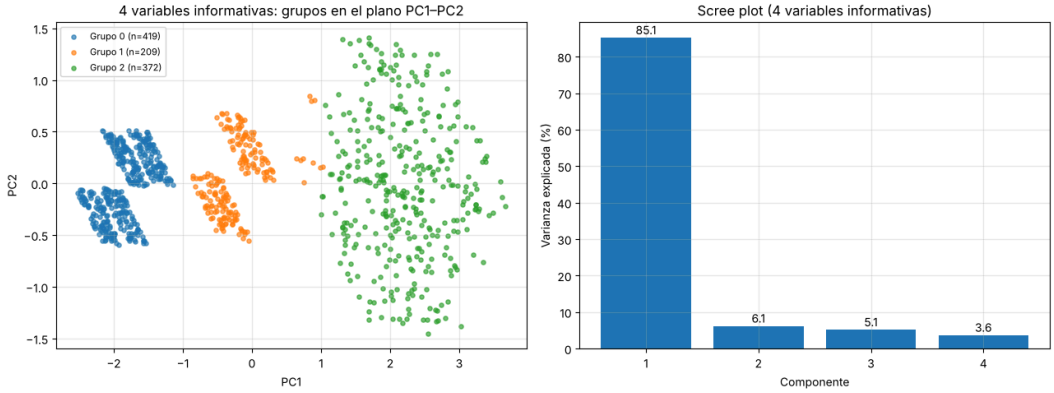
Variante informativa

Si PCA se aplica solo a las cuatro variables de tamaño y valor, el PC1 concentra 85.1 % de la varianza (dos componentes, 91.3 %) y sus cargas son casi iguales (0.49 a 0.51): cuatro variables redundantes se resumen en una. K-Means sobre PC1 solamente reproduce los tres

segmentos del notebook 1 (ARI = 0.995; 419, 207 y 374 inmuebles frente a 419, 209 y 372), con silueta de 0.743 (Figura 12).

Figura 12

PCA y K-Means con las cuatro variables informativas



Nota. Izquierda, grupos en el plano PC1–PC2; derecha, gráfica de sedimentación.

Respuestas a las preguntas del enunciado (PCA)

1. ¿Cuántas dimensiones tenía el conjunto antes del preprocesamiento y cuántas tiene después de PCA?

Antes del preprocesamiento, 6 características (1 000 × 6); después del preprocesamiento, 8 columnas (la localidad se expande en 3); después de PCA, 2 dimensiones (1 000 × 2).

2. ¿Qué porcentaje de la varianza explican los dos primeros componentes?

62.9 %: 45.1 % el PC1 y 17.8 % el PC2. Se pierde el 37.1 %. Para llegar al 80 % hacen falta tres componentes y para el 90 %, cinco.

3. ¿Qué información puede perderse al representar los datos con dos componentes?

Se pierde el 37.1 % de la varianza, de forma desigual: cerca del 85 % del precio, área y habitaciones se conserva, la mitad de baños y antigüedad, y prácticamente nada de la localidad. Además, las distancias del plano distorsionan las reales y los componentes son más difíciles de interpretar que las variables originales.

4. ¿Los grupos de K-Means se distinguen visualmente en el plano PC1–PC2?

Parcialmente. El grupo premium se separa con claridad a lo largo de PC1, con un borde difuso. Los otros dos se separan por una frontera horizontal en PC2, pero es artificial: son inmuebles del mismo precio y tamaño que solo difieren en baños. No hay vacíos entre grupos.

5. ¿Qué diferencias comerciales existen entre los segmentos encontrados?

Comercialmente solo hay dos segmentos: el pequeño (grupos 0 y 1; unos 2 millones de arriendo, 61 m², 1.8 habitaciones; 628 inmuebles) y el premium (grupo 2; 6.35 millones, 156 m², 4 habitaciones; 372 inmuebles). Los grupos 0 y 1 difieren solo en baños, que no se relacionan con el precio. La localidad no distingue ningún grupo.

6. ¿Cambian los grupos al aplicar K-Means sobre los componentes principales?

Depende de cuántos se usen. Con dos componentes cambian (ARI = 0.711; 127 inmuebles); con tres o más son idénticos (ARI = 1.000). Con las cuatro variables informativas, K-Means sobre PC1 reproduce los grupos (ARI = 0.995).

7. ¿Qué enfoque se recomendaría para la inmobiliaria y por qué?

K-Means con k = 3 sobre las variables informativas (área, habitaciones, estrato y precio, estandarizadas), con PCA como herramienta de diagnóstico y visualización, y describiendo los segmentos después con baños, antigüedad y localidad en lugar de usarlas para construirlos. Produce segmentos con sentido comercial, evita la partición artificial por baños, y permite explicar los segmentos en una sola escala de tamaño y valor (ARI de 0.995 al reducir de cuatro variables a un componente). Si en el futuro se demuestra que baños, antigüedad o ubicación influyen en el valor, se incluirían de nuevo.

Parte 3. SVD y clustering jerárquico

Estas dos técnicas son parte de los contenidos del curso (Rojas Reales, 2026c) y complementan lo pedido en la actividad.

PCA es una SVD

Se calculó la SVD de la matriz preprocesada y centrada con `numpy.linalg.svd`. Los valores singulares son 50.557, 31.721, 31.510, 18.324, 18.228, 15.639, 14.105 y 0. La reconstrucción $U\Sigma V^T$ reproduce la matriz con error de 8.5×10^{-15}, las varianzas $\sigma^2/(n-1)$ coinciden con las de PCA (diferencia máxima de 2×10^{-15}) y las direcciones y coordenadas coinciden salvo el signo (diferencias del orden de 10^{-13}). El último valor singular es cero por la colinealidad de las columnas de localidad: la matriz tiene rango 7.

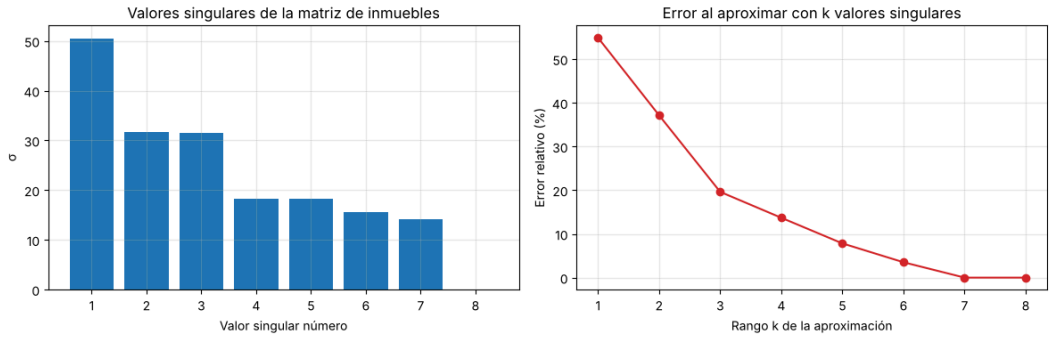
`TruncatedSVD` de scikit-learn no centra los datos. Con la matriz de estos experimentos, que ya está centrada en las columnas numéricas, da los mismos resultados que PCA (45.11 % y 17.76 %). Con las cuatro variables escaladas a [0, 1], que tienen media distinta de cero, la diferencia aparece pero es pequeña (85.59 % frente a 85.64 % en el primer componente). Con datos densos y de tamaño moderado, la herramienta adecuada es PCA.

Aproximación de bajo rango

El error relativo de la aproximación de rango k es igual a 1 menos la varianza acumulada de PCA (Eckart y Young, 1936): con k = 2 se conserva 62.9 %, con k = 3, 80.4 % y con k = 6, 96.5 % (Figura 13).

Figura 13

Valores singulares de la matriz de inmuebles y error de aproximación



Nota. Con 7 valores singulares el error es cero porque el octavo es nulo.

Compresión de una imagen

Se aplicó SVD a la imagen de muestra `china.jpg` de scikit-learn en escala de grises (427 × 640 píxeles, 273 280 números). Con k = 5 valores singulares se guarda 2.0 % de los números y se conserva 96.52 % de la energía; con k = 20, 7.8 % y 98.08 %; con k = 50, 19.5 % y 98.92 %; y con k = 100, 39.1 % y 99.45 % (Tabla 9 y Figura 14). Los valores singulares caen muy rápido, y por eso unos pocos concentran casi toda la información. El ahorro de espacio solo existe mientras k·(m + n + 1) sea menor que m·n, es decir, para k menor que 255 en esta imagen.

Tabla 9

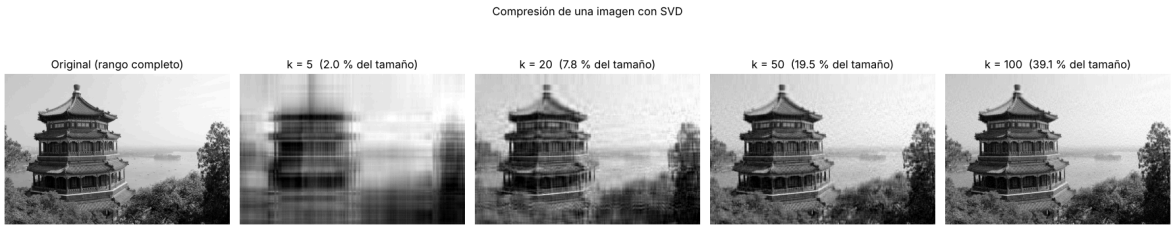
Compresión de imagen con SVD

k	Números guardados	% del original	Energía conservada (%)	Error RMS (niveles de gris)
5	5 340	2.0	96.52	31.12
20	21 360	7.8	98.08	23.10
50	53 400	19.5	98.92	17.36
100	106 800	39.1	99.45	12.37

Nota. Imagen original: 273 280 números. Fuente: notebook 03.

Figura 14

Imagen reconstruida con k = 5, 20, 50 y 100 valores singulares



Nota. Con k = 5 se reconoce la forma general; con k = 20 ya se distinguen los detalles principales.

Clustering jerárquico

Se aplicó clustering aglomerativo a las cuatro variables informativas estandarizadas con cuatro criterios de enlace (Tabla 10). El enlace *single* es el peor (correlación cofenética de 0.449 y un grupo de 735 inmuebles, el efecto cadena). *Ward* logra la mejor silueta (0.477) y los grupos más equilibrados (419, 382 y 199), por lo que se eligió.

Tabla 10

Comparación de criterios de enlace (corte en 3 grupos)

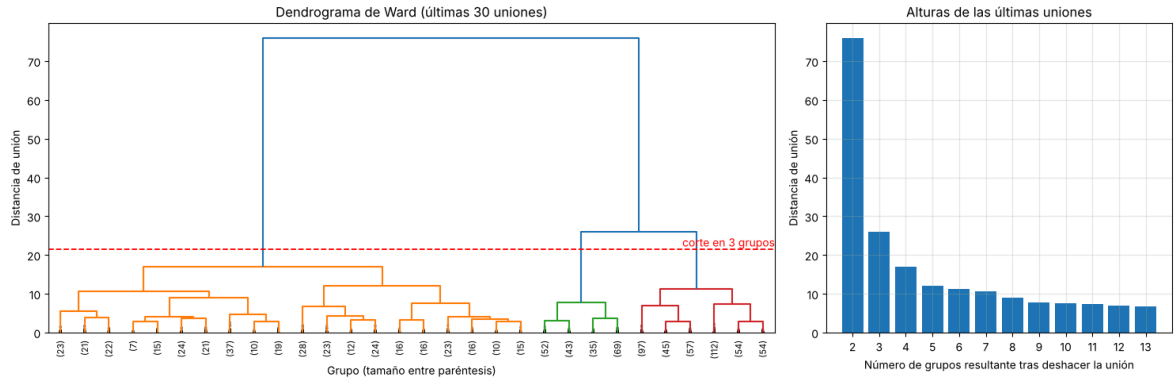
Enlace	Correlación cofenética	Silueta	Tamaños de los grupos
Single	0.449	0.327	735 / 144 / 121
Complete	0.872	0.467	618 / 202 / 180
Average	0.874	0.455	618 / 226 / 156
Ward	0.862	0.477	419 / 382 / 199

Nota. Fuente: notebook 03.

En el dendrograma de Ward (Figura 15), la última unión ocurre a una distancia de 75.96 y la anterior a 26.05; ese salto de 49.9 es el mayor y sugiere dos bloques muy separados. El siguiente salto notable (9.02, de 26.05 a 17.03) justifica un corte en tres grupos, y los saltos posteriores son pequeños. Con k = 3, Ward forma grupos de 419, 199 y 382 inmuebles (1.47, 3.07 y 6.30 millones). Frente a K-Means con k = 3 (Figura 16), Ward difiere solo en 10 de los 1 000 inmuebles (ARI = 0.975); la implementación de scikit-learn y la de SciPy dan la misma partición (ARI = 1.000). Ward, aplicado a las 8 columnas preprocesadas, cae en el mismo problema que K-Means: separa 301 inmuebles de dos baños de 334 de un baño con prácticamente el mismo área (62.6 y 62.2 m²) y precio (2.04 y 2.06 millones), con un ARI de 0.528 frente al resultado informativo.

Figura 15

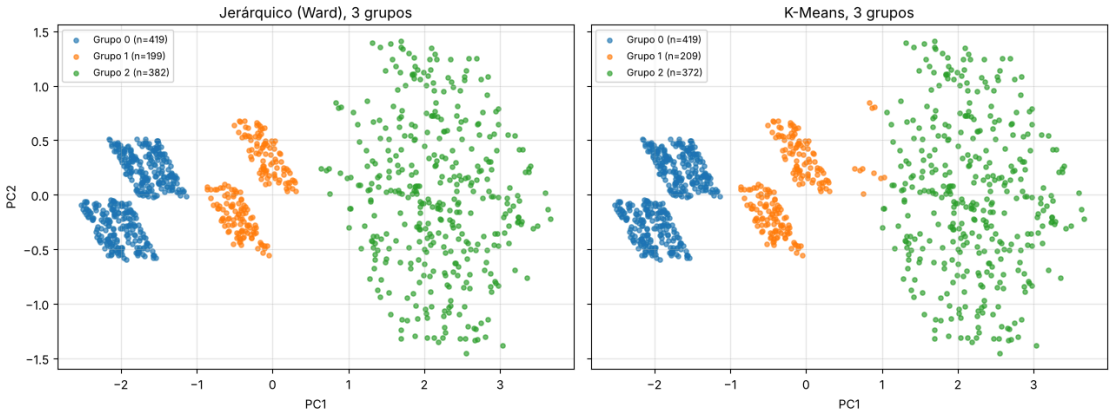
Dendrograma de Ward y alturas de las últimas uniones



Nota. Se muestran las últimas 30 uniones; el tamaño de cada grupo aparece entre paréntesis. La línea roja marca el corte en tres grupos.

Figura 16

Clustering jerárquico (Ward) frente a K-Means con tres grupos



Nota. Plano PC1–PC2 de las cuatro variables informativas; las dos particiones son casi idénticas.

Discusión

El hallazgo central es que un resultado con apariencia correcta puede no tener sentido comercial. Con las ocho columnas preprocesadas, tanto K-Means como Ward separan los inmuebles pequeños por número de baños, una variable que no se relaciona con el precio ni con ninguna otra. La causa no es el algoritmo sino la entrada: tras estandarizar, baños y antigüedad pesan lo mismo que el precio, y los algoritmos de distancia no saben qué variables importan para el negocio. Por eso la selección de variables con criterio comercial es más importante que la elección entre K-Means y clustering jerárquico, y PCA es más útil como diagnóstico, para ver qué variables se agrupan en cada componente, que como paso automático previo al agrupamiento.

Un segundo hallazgo es que la estructura del portafolio es una escalera continua y no un conjunto de islas separadas. Las métricas internas favorecen k = 2, pero k = 3 es la segmentación más útil para decidir. Las métricas orientan y la decisión es del negocio. Por eso los grupos deben leerse como una convención de gestión, no como categorías naturales.

Las limitaciones son tres. Primera, el dataset parece sintético (distribuciones uniformes en baños, antigüedad y estrato, y correspondencia exacta entre localidad y tipo), de modo que los patrones de ubicación o antigüedad que se esperarían en un mercado real no aparecen. Segunda, la decisión de descartar la columna *Estrato* duplicada se apoya en la evidencia de los datos y debe confirmarse con el docente. Tercera, los perfiles de cliente y las estrategias comerciales son hipótesis derivadas de las características de los segmentos y no se validaron con datos de comportamiento.

Conclusiones

K-Means con k = 3 sobre área, habitaciones, estrato y precio estandarizados encuentra tres segmentos útiles: económico (41.9 %), intermedio (20.9 %) y premium (37.2 %), este último con 65 % del recaudo. Escalar es indispensable: sin escalar el modelo agrupa solo por precio. Las métricas internas favorecen k = 2, pero el codo y la utilidad comercial respaldan k = 3.

PCA mostró que el dataset tiene una sola dimensión compartida de tamaño y valor (PC1, 45.1 % de la varianza con las ocho columnas y 85.1 % con las cuatro informativas), y que dos componentes (62.9 %) ocultan la localidad y la mitad de baños y antigüedad. La SVD confirmó que PCA es la descomposición en valores singulares de los datos centrados, y que la compresión de imágenes funciona porque los valores singulares decaen rápidamente. El clustering jerárquico con enlace de Ward coincidió con K-Means (ARI = 0.975) y comparte su sensibilidad a las variables irrelevantes.

Se recomienda a la inmobiliaria usar K-Means con k = 3 sobre las variables informativas, emplear PCA para visualizar y diagnosticar, y describir los segmentos después con baños, antigüedad y localidad.

Referencias

Arthur, D., y Vassilvitskii, S. (2007). k-means++: The advantages of careful seeding. En *Proceedings of the Eighteenth Annual ACM-SIAM Symposium on Discrete Algorithms* (pp. 1027–1035). Society for Industrial and Applied Mathematics.

Caliński, T., y Harabasz, J. (1974). A dendrite method for cluster analysis. *Communications in Statistics*, *3*(1), 1–27. https://doi.org/10.1080/03610927408827101

Davies, D. L., y Bouldin, D. W. (1979). A cluster separation measure. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, *PAMI-1*(2), 224–227. https://doi.org/10.1109/TPAMI.1979.4766909

Eckart, C., y Young, G. (1936). The approximation of one matrix by another of lower rank. *Psychometrika*, *1*(3), 211–218. https://doi.org/10.1007/BF02288367

Golub, G. H., y Van Loan, C. F. (2013). *Matrix computations* (4.ª ed.). Johns Hopkins University Press.

Hubert, L., y Arabie, P. (1985). Comparing partitions. *Journal of Classification*, *2*(1), 193–218. https://doi.org/10.1007/BF01908075

Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering*, *9*(3), 90–95. https://doi.org/10.1109/MCSE.2007.55

James, G., Witten, D., Hastie, T., y Tibshirani, R. (2021). *An introduction to statistical learning: With applications in R* (2.ª ed.). Springer. https://doi.org/10.1007/978-1-0716-1418-1

Jolliffe, I. T., y Cadima, J. (2016). Principal component analysis: A review and recent developments. *Philosophical Transactions of the Royal Society A*, *374*(2065), Artículo 20150202. https://doi.org/10.1098/rsta.2015.0202

Kaiser, H. F. (1960). The application of electronic computers to factor analysis. *Educational and Psychological Measurement*, *20*(1), 141–151. https://doi.org/10.1177/001316446002000116

Kaufman, L., y Rousseeuw, P. J. (1990). *Finding groups in data: An introduction to cluster analysis*. Wiley. https://doi.org/10.1002/9780470316801

Lloyd, S. P. (1982). Least squares quantization in PCM. *IEEE Transactions on Information Theory*, *28*(2), 129–137. https://doi.org/10.1109/TIT.1982.1056489

MacQueen, J. (1967). Some methods for classification and analysis of observations. En L. M. Le Cam y J. Neyman (Eds.), *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability* (Vol. 1, pp. 281–297). University of California Press.

McKinney, W. (2010). Data structures for statistical computing in Python. En S. van der Walt y J. Millman (Eds.), *Proceedings of the 9th Python in Science Conference* (pp. 56–61). https://doi.org/10.25080/Majora-92bf1922-00a

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., y Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, *12*, 2825–2830.

Rojas Reales, W. (2026a). *Actividad: Algoritmos de aprendizaje no supervisado — segmentación de inmuebles en arriendo* [Enunciado de actividad]. Universidad de Cundinamarca.

Rojas Reales, W. (2026b). *DATASET_Inmuebles* [Conjunto de datos]. Universidad de Cundinamarca.

Rojas Reales, W. (2026c). *Introducción a Machine Learning: Aprendizaje no supervisado, reducción de dimensionalidad, PCA y SVD* [Diapositivas de clase, semana 9]. Universidad de Cundinamarca.

Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, *20*, 53–65. https://doi.org/10.1016/0377-0427(87)90125-7

Sokal, R. R., y Rohlf, F. J. (1962). The comparison of dendrograms by objective methods. *Taxon*, *11*(2), 33–40. https://doi.org/10.2307/1217208

Ward, J. H. (1963). Hierarchical grouping to optimize an objective function. *Journal of the American Statistical Association*, *58*(301), 236–244. https://doi.org/10.1080/01621459.1963.10500845

Anexo A. Código principal

Fragmentos de los notebooks. El código completo, con sus salidas, está en https://github.com/RubyDayana/ml-no-supervisado-inmuebles.

A1. K-Means sobre las cuatro variables (notebook 01)

```
VARIABLES = ["Area_m2", "Habitaciones", "Estrato", "Precio_arriendo"]
X = df[VARIABLES]                    # "Inmueble" (el ID) NO está aquí: no se usa para
calcular distancias

scaler = StandardScaler()
X_esc = scaler.fit_transform(X)

def ordenar_por_precio(etiquetas, precios):
    """Renumera los clusters para que 0 sea el de menor precio promedio, 1 el siguiente,
etc."""
    orden = pd.Series(precios).groupby(etiquetas).mean().sort_values().index
    mapa = {viejo: nuevo for nuevo, viejo in enumerate(orden)}
    return np.array([mapa[e] for e in etiquetas])

def ajustar_kmeans(k, datos=X_esc):
    modelo = KMeans(n_clusters=k, random_state=42, n_init=10).fit(datos)
    return modelo, ordenar_por_precio(modelo.labels_, df["Precio_arriendo"].values)

modelo3, df["cluster"] = ajustar_kmeans(3)
```

A2. Preprocesamiento y PCA (notebook 02)

```
df = cargar_crudo()
df.columns = NOMBRES
df = df.drop(columns="Estrato_2")      # columna duplicada sin información
ids = df["Inmueble"]                   # se conserva para interpretar, NO se usa como
característica

variables_numericas = ["Precio_arriendo", "Area_m2", "Habitaciones", "Banos",
"Antiguedad_anios"]
variables_categoricas = ["Localidad"]
X = df[variables_numericas + variables_categoricas]

preprocesamiento = ColumnTransformer(transformers=[
    ("numericas", StandardScaler(), variables_numericas),
    ("categoricas", OneHotEncoder(handle_unknown="ignore"), variables_categoricas),
])
X_preparado = preprocesamiento.fit_transform(X)            # (1000, 8)

kmeans_A = KMeans(n_clusters=3, random_state=42, n_init=10)
grupos_A = ordenar_por_precio(kmeans_A.fit_predict(X_preparado))

pca = PCA(n_components=2)
X_pca = pca.fit_transform(X_preparado)                      # (1000, 2)
print("Varianza acumulada (PC1 + PC2):", pca.explained_variance_ratio_.sum())
```

A3. SVD y clustering jerárquico (notebook 03)

```
Xc = X8 - X8.mean(axis=0)                      # centrar
U, s, Vt = np.linalg.svd(Xc, full_matrices=False)
var_svd = s ** 2 / (n - 1)                     # coincide con PCA().explained_variance_

from scipy.cluster.hierarchy import linkage, fcluster
Zw = linkage(X_inf, method="ward")
ward3 = fcluster(Zw, t=3, criterion="maxclust") - 1
```